

Recurrent Neural Networks (RNNs) and the Exploding & Vanishing Gradient Problems

Tran Le Anh Pha Nguyen Ngoc Hung Le Quang Trung

University of Information Technology

Ngày 21 tháng 12 năm 2025

Mục lục

Đặc trưng của dữ liệu tuần tự

Thứ tự của các phần tử quyết định ý nghĩa: câu chữ, chuỗi thời gian, log hệ thống.

Độ dài có thể biến thiên mạnh và thường được sinh liên tục theo thời gian thực.

Các phụ thuộc xa vẫn ảnh hưởng hiện tại, đòi hỏi mô hình ghi nhớ lịch sử.

Ví dụ: nhận diện thực thể tên riêng trong câu “Harry Potter and Hermione Granger invented a new spell.”

Nhu cầu mô hình hóa chuỗi

Mô hình phải đọc từng phần tử theo thời gian, cập nhật hidden state và đưa ra dự đoán.

Linh hoạt với các cấu hình input/output: Một-Một, Một-Nhiều, Nhiều-Một, Nhiều-Nhiều.

Chia sẻ tham số giúp số lượng trọng số không phình to khi chuỗi dài.

Những yêu cầu trên dẫn tới sự ra đời của RNN.

Tổng quan RNN

RNN sở hữu hidden state H_t cập nhật tuần tự khi đọc dữ liệu.

Trọng số được tái sử dụng cho mọi thời điểm nên tổng quát tốt trên chuỗi dài.

Ứng dụng: mô hình ngôn ngữ, dịch máy, tổng hợp giọng nói, dự báo chuỗi thời gian.

Ưu và nhược điểm

Ưu điểm

Mô tả phụ thuộc theo thời gian với số tham số cố định.

Có thể xử lý đầu vào/đầu ra độ dài bất kỳ.

Nhược điểm

Tính tuần tự cao nên khó song song hóa khi huấn luyện.

Khó học phụ thuộc dài do loss chịu ảnh hưởng mạnh bởi vanishing gradients / exploding gradients.

$$\begin{aligned}H_t &= \phi_h(X_t W_{xh} + H_{t-1} W_{hh} + b_h), \\O_t &= \phi_o(H_t W_{ho} + b_o).\end{aligned}$$

Hidden state ban đầu H_0 thường là vector 0 hoặc tham số học được. Cùng một phép cập nhật áp dụng cho mọi t , thể hiện sự chia sẻ tham số theo thời gian.